

标定对比实验的验证机制说明

"报告值 vs 独立复算"是什么、为什么可信、0.7% 从哪来

配套: TDF_DataProcess/ML_Calibration/REPORT.md(完整报告)· results/results.json(原始记录)·

2026 年 7 月 24 日

1. 先把术语说清楚

1.1 帧(frame)

一帧 = 原始 CSV 里的一行 = 传感器某一瞬间的一次读数(x1, y1, z1 三个磁场值, 单位 uT)。采集时每个力级稳压保持一段时间、连续采样, 所以一个文件有几百行 —— 它们都是同一个力下的重复读数, 只是带噪声在抖。数据规模: Z 轴每对传感器 41 个力级、约 2 万多帧。

1.2 RMSE(均方根误差)

衡量"预测值和真实值平均差多少": 误差先平方(消正负)、取平均、再开根号(单位变回牛顿)。读法: Z-H4 线性模型 RMSE = 0.585 N, 即用线性矩阵测 H4 的 Z 向力, 典型偏差约半牛。RMSE 必须配量程读: 0.28 N 对 20 N 满量程 = 1.4%FS。它对大误差更敏感(先平方), "偶尔大错"比"经常小错"更拉高 RMSE —— 这正是工程上想要的性质。

1.3 限采 200 帧

只发生在训练侧: 每个训练力级随机抽最多 200 帧入训练集(不足则全要); 测试力级的帧全部保留, 一帧不丢。两个原因:

- 信息饱和 —— 同一力级的几百帧 $\approx$ 同一个值 + 噪声, 200 帧已足够估计均值与噪声分布, 再多只是重复, 徒增数倍训练时间;
- 力级等权 —— 文件行数从 271 到 1001 不等, 不限采则录得久的力级在损失函数里占几倍话语权; 限采等于给每个力级"一人一票"。

公平性保证: 抽样用固定种子(每折 = 1000 + 折号), 可复现; 同一折内四个模型共用同一批被抽中的帧。

2. 两列数字是什么

报告中的复现对照表, 两列是同一个物理量算了两遍 —— "留出力级上的力重建 RMSE (N)", 区别只在由谁算出来的:

组合	我的报告 (N)	独立复算 (N)	相对偏差
Z-H4 · 线性模型	0.5854	0.583	约 0.4%
Z-H4 · 二次多项式	0.3378	0.3355	约 0.7% ← 最差
Z-H6 · 线性模型	0.1928	0.1929	约 0.05%
Z-H6 · 二次多项式	0.1280	0.1271	约 0.7%

- 纵向看行与行 $\rightarrow$ 实验结论本身(如 H4: 0.585 $\rightarrow$ 0.338, 二次模型显著更好);
- 横向看左右两列 $\rightarrow$ 数字的可信度(两套独立实现最差只差 0.7%);
- 只复算线性/二次, 因为它们确定性模型(无随机种子, 理应对上, 对不上就是有 bug); MLP 带随机性, 逐位复现无意义, 其可信度由种子间波动($\pm 0.02 \sim 0.08$ N)单独度量。

3. 两遍分别怎么算的: 协议相同、实现独立

这正是"复算"有意义的原因: 协议相同保证可比, 实现不同才能揪出代码 bug。

3.1 相同的部分(协议层, 两边必须一致)

项	约定
数据	同一批原始 CSV(Z 轴 41 力级逐帧数据)
清洗	剔除每个文件末尾的均值行(记录仪追加的统计行, 不是真样本)
输入定义	ΔB = 逐帧读数 - 零力级(0N 文件)均值, 3 通道
划分	4 折按力级交叉: 内部级按"序号 mod 4"轮流留出, 端点(0N/20N)恒在训练集
评估	留出力级的全部帧算 RMSE, 4 折取平均

3.2 不同的部分(实现层, 故意独立)

项	我的报告 (train_calibration.py)	独立复算(净室脚本)
工具库	scikit-learn	纯 numpy, 禁用 sklearn、禁止复用实验代码
数据读取	复用管道的 read_raw_csv()	自行重写读取与均值行剔除(同规则、独立实现)
训练帧	每力级限采 200 帧	全部训练帧, 不采样
线性模型	LinearRegression	np.linalg.lstsq 手解最小二乘
二次模型	StandardScaler → PolynomialFeatures(2) → Ridge($\alpha=1e-3$) 管道	手工构造标准化二阶特征 + 手解岭回归

打个比方: 同一道题, 一个人用计算器、另一个人手算, 约好同样的题目和评分规则, 各自独立做 —— 答案对上了, 才敢说答案是对的, 而不是计算器按错了恰好好看。

4. 0.7% 是什么、不是什么

- 不是模型精度(那是 RMSE / %FS 的事);
- 不是人为设定的阈值(事先设定的可接受容差是 15%);
- 是四组对照中实测的最差相对偏差 —— 有界的诚实表述(报最坏值, 不报最好值)。

微小偏差的来源明确: 主要是"限采 200 帧 vs 全部帧"的训练集差异, 加上两个库数值路径的细微不同。反过来讲: 如果实验代码里存在数据泄漏、划分写错、单位错误这类实质性 bug, 两套异源实现不可能咬合在 1% 以内, 会直接差出一截 —— 这就是该机制的检错原理。

数字	回答的问题	性质
RMSE 0.28 N(1.4%FS)	模型测力有多准?	精度指标
复现偏差 $\leq 0.7\%$	报告里的数字可信吗?	可复现性证据

5. 除数值外还核验了什么

- 对抗性代码审查(独立执行, 含实际运行审计): 按力级划分无泄漏、基线仅来自恒在训练集的零力级、标准化仅在训练集拟合、折覆盖无重复无遗漏、零测试集调参、四模型同折同帧 —— 逐项通过;
- 两条定性结论独立成立: H4 的线性级均值误差在 3–6 N 区间超过 1 N; H6 全程不超过 0.5 N。

6. 一句话总结

先约定同一套实验协议, 再用两套互不参考的实现各算一遍, 以最差 0.7% 的偏差互相咬合 —— 数字因此不依赖任何单一份代码的正确性。这是论文级可复现性(reproducibility)的微缩实践, 也是"用 AI 做科研, 但给 AI 的产出上质检"的具体形态。