

三维磁性力传感器的 AI 标定方案

从解析解耦到学习式标定:设计、证据与实验计划

项目: TDF (Three-Dimensional Force) · 廖梓文 · 2026 年 6 月 30 日

摘要

本方案在现有解析解耦管线 ($F = D \cdot \Delta B$, $D = S^{-1}$) 的基础上,提出一组以数据为依据的机器学习标定尝试。对 158 个标定文件 (约 8.8 万行) 的定量分析证实:线性模型的失效是"按传感器分"的 — H2/H4 在 Z 轴 0-20 N 量程内存在真实的平滑非线性 (最大等效力残差 2.4-2.9 N, 满量程 12-15%), 而 H6 基本线性 ($R^2 = 0.9991$)。据此,本方案的核心不是"用 AI 替换物理模型",而是把学习方法精确地用在解析方法失效之处:以残差学习为主线 (物理矩阵兜底 + 小型神经网络补足非线性), 以多项式回归为科学对照,以高斯过程提供不确定度,并以按力级划分的留出验证保证结论可信。

1. 背景:现有解析管线与它的假设

传感器为 PDMS 弹性体内嵌磁铁的霍尔式三维力传感器 (MLX90393 读取三轴磁场)。现有标定流程:单轴分级加载 → 每个力级采集数百帧磁场读数并取均值 → 最小二乘拟合灵敏度矩阵 S (uT/N) → 求逆得解耦矩阵 D (N/uT) → 实时解算 $F = D \cdot \Delta B$, 其中 ΔB 为去基线后的磁场增量。

这个管线隐含三个假设,每一个都可能在真实材料上失效:

- 线性: 磁场变化与力成正比 — 大形变下 PDMS 呈超弹性,该假设在高载荷段失效;
- 交叉耦合恒定: 三轴串扰是常系数 — 实测部分耦合通道随载荷变化 (见第 2 节);
- 无记忆: 同一 ΔB 恒对应同一力 — 粘弹性迟滞使加载/卸载路径不同 (本方案暂不处理, 见第 5 节)。

2. 数据证据:线性模型到底差在哪 (已双重验证)

以下数字来自对 Raw_Data 全部 158 个标定 CSV 的逐级分析,并经独立脚本复核 (全部结论 CONFIRMED)。数据构成: X/Y 轴各 7 个力级 (0-3 N, 步长 0.5), Z 轴 41 个力级 (0-20 N); 每个力级为数百帧静态重复采样; Y 轴缺 H4。

2.1 主通道线性拟合质量 (Z 轴, 0-20 N)

传感器	R^2 (线性)	最大残差	占满量程	二次拟合改善	定性结论
H2	0.9604	2.92 N	14.6%	22%	有偏差; 其中 15→15.5 N 处含一次约 -134 uT 的夹具移位伪影 (剔除后 $R^2=0.991$)
H4	0.9608	2.41 N	12.0%	65.9%	真实的平滑饱和型非线性; 灵敏度从 0-6 N 段的 -52.1 uT/N 衰减到全程 -30.2 (降 42%)
H6	0.9991	0.46 N	2.3%	26.9%	基本完全线性 (残差已接近噪声水平)

2.2 量程失配实验 (最有说服力的单条证据)

只用 0-6 N 的数据标定斜率,再去预测真实 20 N 载荷 — 模拟"低量程标定、高量程使用"的常见工况:

传感器	真实载荷	线性模型预测	系统性误差
H2	20 N	23.5 N	+3.5 N (+17.6%)
H4	20 N	12.35 N	-7.65 N (-38%)
H6	20 N	22.0 N	+2.0 N (+10%)

2.3 其他关键事实

- 噪声不是瓶颈, 系统性偏差才是: 单帧噪声等效力最差 0.26 N (Z-H4), 力级均值噪声 < 0.011 N; 而 H2/H4 的系统性残差高达 2.4-2.9 N, 超过噪声一个数量级以上;
- 部分交叉耦合随载荷变化: X-H6 的 z1 耦合占主通道 22% 且强烈非线性 (二次拟合改善 94%) — 这正是任何常系数矩阵原理上无法描述的部分;
- Y-H6 标定几何可疑: 其 z1 交叉响应 (+63.1 uT/N) 大于名义主通道 (-59.4), 且强超线性, 提示 Y 向加载时混入了 Z 向分量, 该组数据使用时需谨慎;
- 有效信息量远小于行数: 约 8.8 万行实为 158 个力级均值点 + 噪声分布; 全部为单轴静态加载, 无组合受力、无时间过程 — 这决定了方法选择的边界 (第 5 节)。

3. 方法设计:五个方案, 按优先级排列

方案 ① 残差学习 (Residual Learning) — 主推

$$F = D \cdot \Delta B + f_{\theta}(\Delta B)$$
 (物理矩阵兜底 + 小型网络仅学习物理模型解释不掉的残差)

- 物理模型保底: 网络输出的是小幅修正, 即使外推也不会产生荒唐值;
- H6 上学到的残差 ≈ 0 不是失败而是卖点 — 方法自己知道"哪里不需要 AI";
- 与申请叙事严格对应: "把学习方法精确用在解析方法失效之处"的字面实现。

方案 ② 直接小型 MLP — 对照

每个传感器一个 $3 \rightarrow 32 \rightarrow 32 \rightarrow 3$ 的多层感知机 (约 1300 参数, ReLU), 输入 ΔB 直接回归 F 。与方案 ① 同台对比, 检验"端到端学习"与"物理+残差"孰优。参数量刻意压小 — 数据的有效信息只有每对传感器-轴 7-41 个力级均值, 大网络只会背噪声。

方案 ③ 多项式 / 岭回归 — 必备的科学对照组

数据显示二次拟合就能吃掉 H4 66% 的残差。不设这个对照, 任何内行都会问:"多项式就能解决, 为什么用神经网络?" 主动把 线性矩阵 $\rightarrow$ 多项式 $\rightarrow$ MLP 摆成阶梯, 如实报告分层结果, 本身就是"不把学习模型当黑箱"的最好证明。

方案 ④ 高斯过程回归 (GP) — 差异化加分项

41 个力级均值恰是 GP 的甜点区 (小数据 + 平滑函数)。GP 额外输出预测不确定度 (如 "18 N 处 ± 0.3 N"), 让力读数第一次带上置信区间 — 对申请材料而言, Uncertainty Quantification 是比"训了一个网络"更高一档的关键词。

方案 ⑤ 跨传感器迁移 (few-shot) — 冲刺项

三个传感器灵敏度差异巨大 (主斜率 550 vs 96 uT/N), 说明逐个标定成本高。用 H2+H6 训练、以 H4 的少量力级微调, 验证"新传感器只需少量标定点"的迁移学习叙事。时间不够可以只做初步结果或写进研究计划。

4. 实验设计:决定结论可信度的红线

要点	做法	理由
按力级划分数据集	Z 轴每隔 4 级留出一级作测试 (如 2/4/6...18 N), 其余训练; 绝不按行随机划分	同一力级的数百行几乎相同, 按行随机分 = 数据泄漏, 精度会虚高到没有意义 — 这是本数据集上最典型的 ML 陷阱
只主张插值精度	训练覆盖全量程, 评估留出的中间力级; 不拿神经网络做量程外推	神经网络外推不可靠; 量程失配实验仅用于展示线性法的缺陷
数据清洗	剔除每个 CSV 末尾的均值行 (已在管线中实现); Z-H2 的 15 N 伪影做剔除/保留双版本	训练数据的干净度决定上限; 双版本展示结论稳健性
力级等权	以力级为单位加权, 而非以行为单位	各文件行数 271-1001 不等, 按行等权会让长文件主导拟合
统一指标	留出力级上的 RMSE (N), 分传感器、分轴报告; 全部方法共用同一划分	可直接横向比较; 分层结果 (H4 大改善/H6 打平) 比"全面碾压"更可信

交付物: ① 方法对比表 (线性/多项式/MLP/残差学习 × H2/H4/H6); ② 预测-真值散点图 (线性模型在高载荷段系统性偏离对角线, 学习模型贴合); ③ 残差-力曲线图。三者直接可用于 PS 与面试展示。

5. 明确不做事 (数据不支持, 只进"未来工作")

- 时序建模迟滞 (GRU / 1D-CNN): 现有数据全部是静态稳压值, 没有加载/卸载轨迹。但这是最有价值的"下一步" — 粘弹性迟滞使 $\Delta B \rightarrow F$ 不再是单值映射, 任何只看当前帧的模型(含本方案全部静态模型) 原理上无解, 必须引入时间窗口。写入研究计划, 并规划采集连续变力数据 (参考力传感器 + 100 Hz 同步采样管线已具备);
- 三维组合载荷泛化: 标定数据中组合受力状态为零, 训练出的模型仅在单轴流形附近有效, 不对斜向按压做精度主张; 后续可补采少量组合载荷点作为检验集;
- H4 的 Y 轴: 从未测量 (这也导致其 S 矩阵奇异、可视化端 D 回退为零矩阵 — 建议补测)。

6. 阶段计划与当前进度

阶段	内容	状态
0. 数据卫生	标定管线修复: 均值行剔除、文件完整性校验、 R^2 /残差指标与非线性警告、幂等输出、模块化 (可被训练脚本 import 复用)	已完成 (dev 分支 9 个 commit)
1. 训练脚本	train_calibration.py: 复用 collect_means/read_raw_csv $\rightarrow$ 按力级划分 $\rightarrow$ 四类模型训练与评估 $\rightarrow$ 对比表 + 两张图	待开始 (约一个周末)
2. 结果固化	将真实 RMSE 数字写入 PS / 推荐信 (定性表述), 图表入材料	依赖阶段 1
3. 实时集成	导出网络权重为 CSV $\rightarrow$ Processing 端 30 行前向传播 $\rightarrow$ 界面加 "Linear / NN" 切换按钮, 现场 A/B 演示	可选加分项
4. 研究计划	时序迟滞补偿的数据采集与建模方案, 写入 PS 未来工作	文字工作

7. 与申请叙事的对应关系

整条技术路线与申请材料形成——对应, 每个环节都有可验证的产物支撑:

自建物理管线 (标定 + 矩阵解耦) $\rightarrow$ 从拟合残差发现线性局限 (管线中的 R^2 警告即字面证据) $\rightarrow$ 重新表述为监督学习问题 (放弃"映射必须线性"的先验) $\rightarrow$ 残差学习: AI 只补物理的缺口 $\rightarrow$ 诚实对照 (多项式 / GP), 报告分层结论 $\rightarrow$ 认清静态模型边界 $\rightarrow$ 未来: 时序建模补偿迟滞

- 推荐信: "从拟合残差发现该线性模型在大力值区间存在系统性偏差" — 由 2.1/2.2 节数字直接支撑;
- PS: 填入阶段 1 产出的真实 RMSE 对比与图表; 未来工作写时序迟滞补偿;
- 面试预案: "原来的最小二乘不也是监督学习吗?" — 答: 是, 变化在于放弃线性假设空间; "为什么不用更大的网络?" — 答: 有效样本是力级均值, 大网络只会过拟合噪声。

8. 风险与预期管理

- 最可能的真实结果: 残差学习/MLP 在 H4 上大幅改善、H2 上中等改善 (取决于伪影处理)、H6 上与线性打平 — 这个分层结论比"AI 全面胜出"更可信, 也更能体现方法论素养;
- 多项式可能与 MLP 打平: 如实报告即可, 结论变为"该量级非线性用低阶多项式已足够, 神经网络的价值在于统一框架与向多轴/时序的可扩展性";

- 表述红线: 用"补偿/显著降低" (compensated / markedly reduced), (eliminated / solved) — 材料的粘弹性依然存在, 措辞过满会在面试被戳破。

— 本文档由项目数据分析结果自动汇编, 所有数字均经独立复核 —